



Московский государственный университет имени М.В.Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра суперкомпьютеров и квантовой информатики

Камалов Ирек Маратович

**Исследование методов решения задачи обучения по
нескольким примерам, основанных на применении
ансамбля алгоритмов формирования синтетических
обучающих данных**

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Научный руководитель:
к.ф.-м.н., Д. Ю. Буряк

Москва, 2021

Введение.

- ▶ Многие задачи требуют адаптации к новым целевым меткам
- ▶ Актуально для робототехники - часто требуется адаптация к новым локациям/объектам
- ▶ Требуется и в других областях, пример - сеть GPT-3 для генерации текста



Введение.

- ▶ Адаптация к новым задачам - умение обучаться по нескольким примерам
- ▶ Небольшая входная выборка может быть увеличена методами генерации
- ▶ Цель работы - предложить и исследовать схему ансамблирования генеративных решений

Описание задачи.

- ▶ Рассмотрим задачу классификации изображений
- ▶ Для каждого класса доступно лишь несколько обучающих примеров
- ▶ Допускается использование размеченных изображений нецелевых классов
- ▶ На количество таких примеров ограничений нет

Обзор тематики.

- ▶ Оптимизация эмпирического риска приводит к переобучению
- ▶ Для борьбы с проблемой используется перенос обучения из других задач




Рис. 1: Разделение подходов.

Генеративный подход.

- ▶ Строится алгоритм генерации искусственных примеров
- ▶ С помощью алгоритма создается искусственная выборка
- ▶ На выборке обучается классификатор

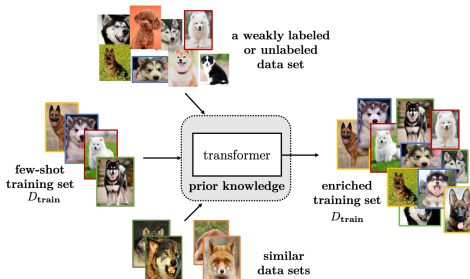


Рис. 2: Трансформация примеров.

Постановка задачи.

- ▶ Провести обзор методов генерации искусственных выборок для решения задачи классификации
- ▶ Выбрав наиболее подходящие методы, предложить ансамбль алгоритмов генерации
- ▶ Реализовать предлагаемое решение
- ▶ Провести исследование точности решения с учётом возникающих гиперпараметров

Решение задачи с помощью ансамбля генераторов.

Дельта-кодировщик $\Delta Encoder(X_1, X_2, Y)$

- ▶ Модель обучается кодировать мета-связи примеров X_1, X_2 и по этой информации воссоздавать неизвестную пару для Y




Рис. 3: Кодирование мета-связей.

Решение задачи с помощью ансамбля генераторов.

Центроидный генератор $G(C_{1a}, C_{2a}, C_{1b}, C_{2b})$

- ▶ Векторы кластеризуются, в кластерах остаются лишь центроиды
- ▶ Регрессия парной центроиды C_{2b} по C_{1b} и паре (C_{1a}, C_{2a})





Рис. 4: Регрессия парных примеров.

Решение задачи с помощью ансамбля генераторов.

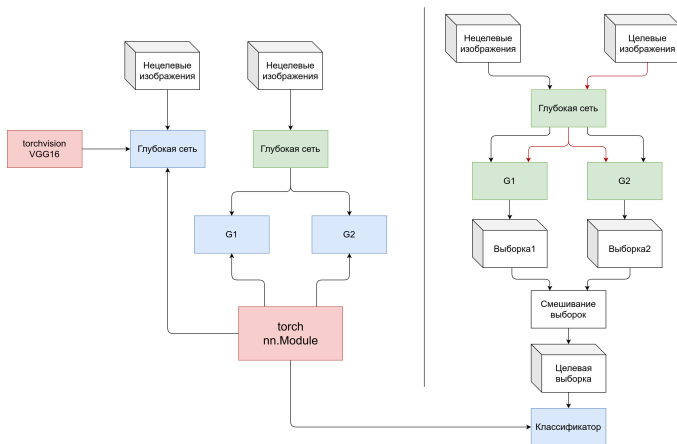
Ключевые идеи ансамбля:

- ▶ Перевод всех изображений в векторы признаков
- ▶ Построение выборок генераторами по отдельности
- ▶ Смешивание полученных выборок
- ▶ Обучение классификатора на смешанной выборке



Программная реализация.

Красные блоки - заимствование кода/весов, синие - обучение моделей, зелёные - использование моделей



Реализация НС с помощью Python 3.7, PyTorch, NVIDIA Tesla V100

Вычислительный эксперимент.

- ▶ Были рассмотрены 2 модельные задачи minImageNet и CIFAR100
- ▶ В каждой задаче было выделено 80 тренировочных классов, на которых обучались генераторы
- ▶ Оценка качества на 5 классах, не вошедших в тренировочные
- ▶ Метрика качества - точность

Вычислительный эксперимент.

- ▶ Все изображения были переведены в пространство \mathbb{R}^{2048} сетью на базе VGG16
- ▶ Каждым генератором была воссоздана выборка из 1024 примеров
- ▶ Целевой классификатор - однослойный персептрон

Результаты эксперимента.

minilImageNet:




Рис. 5: Точность для различных соотношений при смешивании.

Входных примеров	G1	G2	G1 + G2 (смесь 0.51 : 0.49)
1	58.9%	56.9%	64.2%
5	75.9%	74.5%	80.1%

Таблица 1: Рекордная точность для 3 типов выборок.

Результаты эксперимента.

CIFAR100:




Рис. 6: Точность для различных соотношений при смешивании.

Входных примеров	G1	G2	G1 + G2 (смесь 0.9 : 0.1)
1	64.4%	64.7%	69.2%
5	79.4%	76.9%	83%

Таблица 2: Рекордная точность для 3 типов выборок.

Выводы.

Выводы из эксперимента:

- ▶ Смешивание выборок улучшает качество решения на 3-6%
- ▶ Оптимальное соотношение для смешивания зависит от задачи
 - ▶ 0.59 : 0.41 - наилучшая смесь для minilImageNet
 - ▶ 0.9 : 0.1 - наилучшая смесь для CIFAR100
- ▶ Данное соотношение - гиперпараметр ансамбля

Основные результаты.

- ▶ Проведён обзор методов генерации искусственных выборок
- ▶ На основании обзора выбрано 2 метода для построения ансамбля
- ▶ Выполнена реализация ансамбля и исследование на базах minilmaNet, CIFAR100
- ▶ Получен прирост точности для ансамбля относительно отдельных решений
- ▶ Сделан вывод: соотношение выборок при смешивании - новый гиперпараметр